

一种新颖的教师评价模式

1

分支路径：一种用于教师发展的新型教师评价模型

金·A·帕克,¹ 詹姆斯·P·巴维斯,¹ 以及安·G·努²

普渡大学英语系

² 四城大学教育心理学系教师教育中心

注释[AF1]: 运行标题是论文标题的缩写版, 出现在每一页上。它全部用大写字母书写, 并且应该左对齐在文档的页眉中。在 APA 7 中不包含“运行标题:”的标签。如果论文标题少于 50 个字符(包括空格和标点符号), 则可以使用实际标题而不是缩写形式。

注释[AF2]: 页码从首页开始, 并在随后的每一页上连续编号, 不得中断。不需要其他信息(例如, 作者姓氏)。

注释[AF3]: 论文标题应居中、加粗, 并使用标题大小写书写。它应位于页面顶边距下方三到四行。在这份样本论文中, 我们在标题上方留了三行空白。

注释[AF4]: 作者姓名应出现在标题下方双倍行距的一行中。应按以下方式书写: 名字、中间首字母、姓氏。省略所有职业头衔和/或学位(例如, 博士、牧师、哲学博士、硕士学位)。

注释[AF5]: 作者姓名之后紧接着是作者的所属机构。如果作者代表多个机构, 如本样本中的情况, 使用上标数字来表明哪位作者与哪位机构有关联。如果所有作者都代表同一机构, 则不要使用任何数字。

作者注释

金·A·帕克  <https://orcid.org/0000-0002-1825-0097>

詹姆斯·P·巴维斯现就职于威斯康星州绿湾的麦克劳德音乐教育学院。

我们没有已知的利益冲突需要披露。

关于本文的通信应寄往安·G·努(Ahn G. Nu), [部门]

教育心理学, 华盛顿州夸德市普罗克特街北 253 号。电子邮件: agnu@qcityu.com 邮编: 99291

注释[AF6]: 作者注释按此顺序包含以下部分:

1. 醒目且居中的“作者注”标签。
2. ORCID 身份识别码
3. 作者所属单位的变化
4. 披露/致谢
5. 联系信息。每部分均为可选(即, 您应省略任何不适用于您的手稿的部分, 或者如果都不适用则完全省略注释)。将每项格式化为单独的缩进段落。

评论[AF7]: ORCID 是一个允许研究人员和学者注册职业档案的组织, 以便他们能够轻松地相互联系。要在作者注中包含 ORCID 身份标识, 只需提供作者姓名, 后跟绿色的身份标识图标(超链接到后面的网址)以及到相应 ORCID 页面的超链接即可。

摘要

大量的评估文献表明，学生对教师的评价（SETs）在各种情境中可能无法准确衡量教学这一构念。这可能会影响依赖 SETs 提供的信息进行教师发展的努力。在需要特定教学技能的教育情境中，如果 SETs 对这些技能的重视程度与它们在当地的重要性不成比例（或者根本不测量），那么 SET 结果与教师发展努力之间的脱节就会加剧。本文通过提出一种评估教学的工具来应对这些挑战，该工具允许机构利益相关者以他们认为适合当地情境的方式定义教学构念。与传统的 SETs 相比，该工具的主要创新之处在于，它采用了基于特纳和厄普舒尔为 ESL 写作评估开发的实证推导的二元选择、边界定义（EBB）量表的分支“树”结构，其中填充了二元选择题。本文认为，这种结构能够使利益相关者通过改变可能结果树中节点的顺序和敏感度来定义教学结构，每个节点对应于一种特定的教学技能。本文最后概述了一项试点研究，该研究将考察所提出的 EBB 工具与采用一系列对应于李克特量表值的单项选择题（MCQ）的传统 SET 之间的差异。

关键词: 大学教学、学生对教学的评价、量表开发、Ebb 量表、教学法、教育评估、教师发展

注释[AF8]: 请注意，在标题之后的页面上，页眉和页码都会继续显示。

注释[AF9]: “摘要”这个词应在页面顶部居中并加粗。

[AF10] 评论道: 按照标准惯例，摘要中不应包含对其他作品的引用。如果您在摘要中需要引用其他作品，在正文中提及作者通常就足够了。还要注意，一些机构和出版物可能允许在摘要中引用。

评论[AF11]: 摘要迅速总结了后续论文的要點。APA 7 版手册并未给出关于摘要应多长的明确指示，但它确实提到大多数摘要不超过 250 个单词（第 38 页）。它还指出，专业出版商（如学术期刊）对于摘要可能有各种规定，作者通常应遵循这些规定。

评论[AF12]: 摘要的主要段落不应缩进。

[AF13] 评论: 在摘要之后附上一些关键词，这些关键词要能描述您论文中的重要观点或主题。这有助于在线读者在数据库中搜索您的论文。

关键词列表的第一行应缩进 0.5 英寸。以“关键词:”（注意斜体和冒号）开头，随后列出以小写形式（除了专有名词）写的关键词，用逗号分隔。列表末尾不要加句号。

分支路径：一种用于教师发展的新型教师评价模型

根据西尔（2017 年）的观点，“教师的评估和发展不能分开考虑……没有发展的评估是惩罚性的，没有评估的发展是猜测性的”（第 91 页）。随着构成现代规划性教师发展的实践从最初的简单形式发展到成为大学生生活中常见的特征（刘易斯，1996 年），出于发展目的评估教学教师能力的各种策略同样变得普遍。这些策略包括诸如同行观察、教学档案的开发以及学生评价等各种各样的措施。

其中一种衡量标准，即学生对教师的评价（SET），至少自 20 世纪 90 年代以来几乎无处不在（威尔逊，1998 年）。尽管类似 SET 的衡量工具的记录可以追溯到 20 世纪 20 年代在普渡大学的工作（雷默斯和布兰登伯格，1927 年），但大多数现代师资发展史表明，它们在 20 世纪 70 年代随着现代师资发展项目的诞生而广泛流行起来，当时各大学开始采用这些项目以回应学生抗议活动，这些抗议活动批评了主流的大学课程和教学方法（加夫和辛普森，1994 年；刘易斯，1996 年；麦基奇，1996 年）。到 21 世纪中期，研究人员已经开始将 SET 描述为“……全球范围内衡量大学教师表现的主要标准……”（庞德，2007 年，第 178 页）。如今，在大多数大学中，SET 在教师评估和师资发展中发挥着重要作用（戴维斯，2009 年）。近期的 SET 研究实际上将大多数校园中存在某种形式的这种评估视为既定事实。例如，斯波尔伦等人（2017 年）只是指出，几乎在世界各地的每一所高等院校都能发现自我评价（p. 130）。同样，达尔文（2012 年）将教师评价视为一种既定的正统做法，称其为一种“备受尊崇的”、“公理化的”制度性实践（p. 733）。

此外，战略与绩效评估不仅有助于大学明确其师资发展工作的方向，而且由于其作用，它们在制度上已占据了相当重要的地位。

评论[AF14]：论文标题应加粗并居中，位于正文第一段上方。不应有“引言”标题。

注释[AF15]：在此，我们引用了外部来源的一句话，所以我们需要在括号中提供引文在文档中的位置（在本例中，是页码）。

注释[AF16]：相比之下，在这里，我们只是对外部来源的一个观点进行了释义。因此，不需要位置或页码。

注释[AF17]：首次使用缩写时将其拼写出来，但非常知名的缩写（例如“CIA”）除外。

注释[AF18]：对于有两个作者的来源，在作者姓名之间使用连字符（&），而非“和”这个词。

注释[AF19]：在同一括号中列出多个引文时，按字母顺序排列，并用分号分隔。

一种新颖的教师评价模式

4

人员考量，影响着诸如招聘、解雇、任期和晋升等重要决策。塞尔丁（1993 年；引自庞德，2007 年）发现，86%的高等教育机构将学生评价作为人事决策的重要因素。1991 年对系主任的一项调查发现，97%的人使用学生评价来评估教学表现（美国教育部）。自 20 世纪 90 年代中后期以来，观察到一种总体趋势，即教师评价的综合方法包括多种形式的评估。

注释[AF20]: 在此，我们进行了间接引用或二次引用（即，我们引用了在另一来源中发现被引用的来源）。在括号中使用“如引述于”这一表述来表明第一个列出的来源在第二个列出的来源中被引用。仅在参考文献列表中为二次来源（在本例中为庞德）添加条目。

（伯克，2005 年）。然而，近期研究表明，在人事决策中使用学生评价仍然极为常见，尽管确切的百分比难以得出，这或许是由于这些决策的多面性（博林等人，2017 年；高尔布雷思等人，2012 年）。在某些情况下，学生评价的影响可能超出个体教师的层面。特别是在近几十年来，公立学校面临着采用新自由主义、市场化的自我评估方法以及培养学生作为消费者的思维模式的压力（达尔文，2012 年；马金森，2009 年），评价中的信息甚至可能出现在系或全校范围的资金决策中（例如，奥巴马政府的“力争上游”计划，该计划向采用增值模型进行教师评价的 K-12 机构提供拨款）。

注释[AF21]: 在此，我们引用了一个没有署名作者的来源。相应的参考文献列表条目将以“美国教育部”开头。

注释[AF22]: 有三个或更多作者来源的参考文献，应通过首位列出作者的名字后加上拉丁短语“et al.”来引用。请注意，句号应加在“al”之后，而不是“et”之后。

然而，尽管标准教育测试（SETs）在许多教育机构的错误发展和人事决策中起着关键作用，但目前的标准教育测试管理方法并不适合这些目的。本文认为，针对当地背景需求而开发的教师评价的建构性、实证方法更适合帮助机构改进教师。本文提出了教师的赫维隆评价（Heavilon Evaluation of Teacher，简称 HET），这是一种新的教师评估工具，能够通过使当前的方法对教师的当地背景更具响应性来强化当前的方法。本文还提出了一项试点研究，以阐明这种新工具与普渡大学入门写作（ICaP）标准教育测试（一种用于类似目的的更传统工具）之间的差异。该研究的结果将指导未来完善所提议工具的努力。

注释[AF23]: 为简洁起见，原始文件的下一页已从这份样本文件中裁剪掉。

接下来的方法部分将提出一项试点研究，该研究将比较所提议的工具的结果与传统的 SET 的结果（还将提供关于这两种评估的必要背景信息）。本文将以讨论试点研究的结果将如何为所提议工具的未来迭代提供信息，以及更广泛地说，大学应如何主张在本地开发评估作为结尾。

文献综述

有效教学:一个情境性构建

本文所提出工具的有效性取决于这样一个观点，即有可能系统地衡量教师的教学能力。实际上，对于几乎所有的教师评估来说，都可以这么说。然而，尽管自我效能感量表（SETs）以及依赖其输入的教师发展项目极为常见，但对于究竟什么构成“良好”或“有效”教学，学者们几乎没有达成共识。由于围绕教学有效性的争论历史悠久，范围广泛，要回顾其整个历史是不可能的——例如，这样的总结可能需要从西塞罗和昆提利安开始。然而，对近期重要发展（特别是那些在教学实证研究的荟萃分析中所揭示的发展）的粗略概述，有助于将本文所提出的工具置于相关的学术对话中。

注释[AF24]: 二级标题左对齐、加粗，并采用标题大小写书写。三级标题左对齐、加粗、采用标题大小写书写，并加斜体。

元分析 1. 支撑许多此类对话的一个核心假设是，良好的教学在学生成绩方面能够产生可观察到的影响。一项对167项实证研究的元分析（Kyriakides等人，2013年）支持了一组教学因素的有效性，这些因素被作者归为“动态教学模型”。八个因素中有七个（定向、结构化、示范、提问、评估、时间管理和课堂作为学习环境）在学生成绩的测量中对应于中等平均效应大小（标准偏差在0.34-0.41之间）。

注释[AF25]: 四级标题为粗体，以标题大小写书写，并以句号结尾。它们也缩进，并与接下来的段落齐行书写。

[AF26] 评论: 在呈现小数分数时，如果数量可能超过 1（例如此处标准偏差数），则在小数前加零；如果数量不可能超过 1（例如，如果数量是一个比例），则不加零。

学生成绩。第八个因素是应用（定义为课堂作业和小组任务，旨在练习课程概念），其影响大小仅为0.18，虽然较小但仍具有重要意义。在荟萃分析中，缺乏任何单一的决定性因素，支持了有效教学很可能是多变量结构体的观点。然而，作者也指出有效教学的上下文相关性。应用，总体上是最不重要的教学因素，但在研究年轻学生时却显得尤为重要（第148页）。相比之下，建模对年长学生尤为重要。

元分析 2. 另一项元分析强调了诸如清晰度和设定具有挑战性的目标等因素的重要性（哈蒂，2009 年），但也发现各种教学因素的效果大小可能高度依赖上下文。例如，根据所研究的教育水平，家庭作业的效果大小从 0.15（小效果）到 0.64（中等大的效果）不等。对于学术科目（例如数学与英语）的差异以及学生能力水平，也观察到了类似的范围。正如斯努克等人（2009 年）在对哈蒂的批判性回应中所指出的，虽然有可能得出特定教学因素平均效果大小的数字，但这样的平均数掩盖了上下文的重要性。

荟萃分析 3. 最终的荟萃分析（塞德尔和沙维尔森，2007 年）发现，大多数教学因素的平均效应大小通常较小——组织和学术领域特定的学习活动显示出最大的认知效果（分别为 0.33 和 0.25）。然而，在这里，同样由于诸如学习领域和教育水平等情境因素，效果差异很大，而平均效应大小并未体现出来。

这些证据表明，存在多个教学因素能够使学生的成绩产生可衡量的提升，并且这些因素的相对重要性可能高度依赖于诸如学生身份等情境因素。这与教育研究中一个有充分记录的现象相符，该现象使得纯粹从学生成绩的角度来衡量教学效果变得复杂。即“学生学习差异的最大来源归因于学生带到学校的东西——他们的”

一种新颖的教师评价模式

8

能力和态度，以及家庭和社区”（麦肯齐等人，2005年，第2页）。由于非教师因素如社会经济地位和家庭生活等，学生的成绩差异很大（斯努克等人，2009年）。这意味着，即使有可能观察到某些教学行为在学生成绩方面的有效性，也很难为学生成绩设定可推广的基准或标准。因此，在不同教育背景下对教学效果进行真正的比较也很困难：由于不同类型学生之间的巨大差异，在一个背景下构成高效教学的概念在另一个背景下可能并不存在。这种困难在批评某些声称能对教学因素产生最大影响的元分析时也出现了（哈蒂，2009年）。几十年来，其他评论员也提出了类似的观点，认为情境因素在教学效果中的重要性（例如，布鲁姆等人，1956年；卡辛，1990年；西尔，2017年）。

上述研究主要从学业成绩的角度来衡量教学效果。当然，应当指出的是，这些可量化的衡量标准通常不被视为有效教学值得追求的唯一成果。诸如对学习的亲和力增强以及自我效能感增强等定性成果也是重要的学习目标。在这里，当地的背景也起着很大的作用。

[AF27] 评论道：“若要将几个来源列为大量研究成果中的示例，您可以在括号中使用‘见’这个词，正如我们在此所做的。”

标准集:不完美的教学衡量标准

正如本文引言所述，学生评价表通常用于评估教学表现和为教师发展提供信息。通常，这些评价表以期末总结性评价的形式呈现，包括多项选择题（MCQ），允许学生以李克特量表的形式对教师的陈述进行评分。这些评价表通常还附有简短的回答，这些回答可能是可选的，也可能不是。

学生评价教学（SETs）服务于重要的制度性目的。尽管评论员指出，存在一些关键的教学方面是学生无法评判的（本顿和杨，2018年），但学生评价教学仍然为学生提供了一种难得的制度性发声渠道。它们代表着一个机会

学生能够就他们的教学体验提供匿名反馈，并有可能指出他们认为教师的成功或失败之处。学生也处于独特的有利地位，能够就教师的教学提供有意义的反馈，因为他们通常比任何其他教育利益相关者对教学过程有更广泛的第一手经验。即使是同行观察员在给定学期期间也只能见证一小部分教学课程。相比之下，全勤的学生会见证所有课程。因此，从某种意义上说，学生理论上能够比同行导师更权威地评估教师的能力。

尽管历史上对学生评价（SETs）有效性的验证尝试结果不一，但一些研究已经证明了它们的前景。例如，霍华德（1985 年）发现，学生评价对教学效果的预测能力明显优于自我报告、同伴和训练观察员的评估。对几十年来有关教学评估的文献的回顾（沃切尔，1998 年）发现，尽管偶尔存在疑虑，但大多数研究人员认为学生评价总体上是有效和可靠的。该回顾指出，即使是支持学生评价的学者也经常认为，仅靠学生评价无法指导改进教学的努力，多种反馈途径是必要的（L'hommedieu 等人，1990 年；塞尔丁，1993 年）。

最后，学生评价问卷还有除表面上的改善教学之外的其他用途，尽管这些用途的重要性较低。例如，它们可以用来增强教师的简历和颁发部门奖项。学生评价问卷还能提供与教学无关的有价值信息。很难说教师了解学生觉得这节课无聊得难以忍受，或者学生觉得老师的个性非常令人讨厌以至于妨碍了学习，对教师没有用处。简而言之，了解学生对特定课程的情感体验确实有价值，即使在这种情况下，这种价值不一定能得出关于教师专业能力的明确结论。

然而，大量的学术研究表明，在特定情境中，自我效能感容易失效。一个常见的批评意见是，自我效能感常常会受到某些因素的干扰。

超出了教学结构的范畴。关于这一主张的研究基础的最佳介绍可能是尼思（1996 年），他通过向教学人员提出二十条讽刺性的建议来呈现这些外部混淆因素，从而进行了某种元分析。其中包括“宽松评分”、“在考试前进行评级”（第 1365 页）以及“不要教授必修课程”（第 11 条，第 1367 页）等建议。尼思的大多数建议反映了一个压倒性的观察结果，即教学评估往往记录的是学生对课程的情感感受，而非教师的能力，即使评估明确要求学生对后者进行评判也是如此。

[AF28] 评论道：此引文呈现了来自原始资料不同位置的引述。每段引述后面都跟着相应的页码。

除了内斯之外，许多现有研究也描绘了类似的图景。例如，一项针对超过3万名经济学学生的调查得出结论，“学生认为老师越贫穷，他们对经济学的理解就越多”（阿蒂耶和卢姆斯登，1972年）。1998年的一项荟萃分析指出，“没有证据表明教师评分的使用在长期内能改善学习”（阿姆斯特朗，1998年，第1223页）。2010年国家经济研究局的一项研究发现，一门课程的教师在学生评价中的高得分与“同时期的课程成绩”相关，但与“后续成绩”相关性较低”（换句话说，学生在这门课程中往往表现良好，但在同一研究领域的后续课程中表现不佳。观察到这一影响的其他研究者认为，学生评价体系奖励的是在初始课程中迎合学生的“软球”教学风格”（卡雷尔和西斯特，2010年）。最近的研究表明，课程主题对学生评价体系得分也有显著影响：“定量课程”（即数学重点课程）的教师往往比人文课程的教师得到学生评价得分低（乌特和斯米伯特，2017年）。

多项现代的 SET 研究也表明存在基于性别（安德森和米勒，1997 年；巴索，1995 年）、外貌/性感（安巴迪和罗森塔尔，1993 年）以及其他不影响教学质量的身份标识的偏见。尤其是性别，已经引起了极大的关注。最近的一项研究考察了两个在线课程：一个课程中，教师向学生表明自己是男性；另一个课程中，教师表明自己是女性。

女性（无论教师的实际性别如何）（麦克内尔等人，2015 年）。这些课程在结构和内容上是相同的，教师的真实身份对学生是隐藏的。该研究发现，学生平均对男性身份的评价更高。然而，一些研究表明上述性别偏见是相反的（即女性获得更高的分数）（巴肯等人，1999 年），而其他一些研究则表明不存在任何形式的性别偏见（森特拉和豪巴特兹，2000 年）。

提出这些批评的目的不一定是贬低 SETs 在制度上的重要性。当然，只要制度重视对学生的指导，那么让学生在指导的内容和特点方面有一定的发言权是很重要的。相反，这里的目的是简单地表明，将 SETs 用于教师发展目的——更不用说人事决策——可能会带来问题。这也是为了说明，尽管关于 SETs 的文献众多，但学术界仍有很大的空间来尝试使这些工具更有用。

实证量表与本地相关评估

确保教学评估能更好地响应教师所在情境需求的一种方法是，在当地开发这些评估，理想情况下，这一过程应涉及各种当地利益相关者的投入。在这里，写作评估文献提供了一个有前景的前进道路：实证量表开发，即根据当地输入和数据（例如，在写作评估的背景下，学生的写作样本和表现信息）构建和校准工具的过程。例如，这种做法与试图呈现预先确定的理论结构以便结果能够被泛化的演绎量表开发方法形成了对比。

实证过程的支持者认为，实证量表有几个优点。它们经常被提出作为解决有充分文献记载的可靠性问题以及有效性问题的潜在解决方案，这些问题在理论或直觉量表的开发中可能会出现（布林德利，1998 年；特纳和厄普舒尔，1995 年、2002 年）。实证量表还可以帮助研究人员避免由此导致的问题

在其他类型的量表中，依据主观或措辞模糊的标准（布林德利，1998 年），因为它们需要当地利益相关者的认同，而这些利益相关者必须基于对当地背景的理解对这些标准达成一致。例如，富勒等人（2011 年）指出以下内容：

以测量为导向的量表存在描述不足的问题。它们对交际语境或语言使用的互动复杂性不敏感。抽象程度过高，导致评分与其意义之间存在鸿沟。只有对基于情境的表现进行更丰富的描述，我们才能强化评分的意义，进而增强基于评分的推论的有效性。（第8-9页）

也有一些证据表明，EBB 量表的分支结构尤其能够允许更可靠和有效的评估，尽管通常使用常规量表进行校准和使用要容易得多（平井和小泉，2013 年）。最后，学者们还认为，基于理论的量表开发方法并不总是能产生能真实捕捉普通课堂情况的工具（克诺赫，2007 年，2009 年）。

文献中对实证量表开发的批评最为普遍，即实证量表的局部性和偶然性本质基本上摒弃了其结果的可推广性。例如，富勒（2003 年）对 EBB 量表提出了这一基本批评，但随后他指出“EBB 设计方法的明确性令人印象深刻，其在教学环境中的实用性也很有吸引力”（第 107 页）。就本文的目的而言，还有一个事实是，支持实证量表开发的文献源自写作评估领域，而非教学评估领域。此外，针对实证量表开发在后者目的中的应用，现存研究很少。因此，无法保证实证开发方法带来的益处能够在教学评估领域得以实现。也无法保证它们不能实现。在朝着更好地理解这些评估模式在新情境中如何运作迈出初步一步时，下一节所描述的研究

评论[AF29]: 超过40个单词的引语应以块状引语的形式呈现。将整个段落缩进半英寸，并省略引号。如果引文未提及作者和/或日期，应将其与页码一起放在引文后的括号中。

注释[AF30]: 当引用同一作者的多处来源时，只需列出作者姓名，然后用逗号分隔列出这些来源的年份。

它询问，指导一些评估学生最有前景的做法的原则，能否在评估教师方面得到有效利用。

材料与方 法

本节提出了一项试点研究，将ICaP SET与Heavilon教师评估（HET）进行比较，后者是一种旨在应对上述统计上限效应的工具。在本节中，描述了HET的格式和构成，特别关注其分支量表设计。随后，概述了研究程序，并讨论了对数据的计划性解释。

普渡大学信息与计算科学学院编程与算法竞赛

截至 2019 年 1 月，普渡大学入门写作（ICaP）项目所采用的自我评价表（SET）是当前自我评价表管理中许多流行趋势的一个例子。该评价以数字形式进行：ICaP 项目的学生在学期末附近会收到通过电子邮件完成的评价邀请，并且必须在期末考试周（即正常十六周学期之后的一周）之前完成，否则他们的回答将不被计入。该评价完全自愿：教师可能不要求学生完成，也不得提供诸如额外学分之类的激励措施来推动。然而，一些教师选择留出少量课堂时间来用于评价。在这些情况下，教师通常的做法是离开教室，以免影响高分。

ICaP SET 主要以简单的多项选择题调查的形式呈现。调查中有 34 道多项选择题。其中，前四道与人口统计数据有关：学生必须表明他们的学年、预期成绩、所学领域以及他们是作为必修课还是选修课来修读这门课程。接下来是两个与课程整体质量和教师相关的问题（学生必须以五分制从“非常差”到“优秀”对每个方面进行评分）。这些是“大学核心”问题，无论在普渡大学哪个学院、专业或课程中进行的每次 SET 调查都必须包含这些问题。学生们

还受邀对两个简短回答的提示作出回应：“对于改进这门课程或其教学方式，您有什么具体建议？”以及“教授做得好的方面是什么？”对这些问题的回答是可选的。

其余的多项选择题（总共三十道）是从由普渡大学教师课程评估服务（PICES）提供的 646 个可能的问题列表中选出的。这些问题中的每一个都要求学生以五级李克特量表的形式对有关课程的陈述做出回应。李克特量表是一种简单的量表，用于表明同意的程度。就 ICaP SET 而言，学生必须表明他们是*强烈同意*、*同意*、*不同意*、*强烈不同意*还是未决定。这三十道李克特量表问题评估了课程和教师的多种品质。例如，“我的老师看起来为上课做好了充分准备”、“这门课程帮助我分析自己和其他学生的写作”以及“当我有问题或意见时，我知道它们会受到尊重”等等。

注释[AF31]：将量表或对类似量表问题的回答的锚点用斜体呈现，而非用引号。如果量表回答是编号的，则不要将数字用斜体。

普渡大学英语系内 ICaP SET 带来的一个重要后果是卓越教学奖（在 2018 年秋季之前，该奖项被称为昆蒂利安奖，俗称“Q”奖）。这是每学期颁发给在评估中得分高的研究生导师的一个象征性奖项。根据 ICaP 网站的说法，“教学评估达到一定阈值的 ICaP 导师将获得[该奖项]，以表彰普渡大学教学评估排名前 10% 的导师。”虽然这一描述具有误导性——该奖项实际上是颁发给 SET 得分在可能结果范围内排名在前十分之一的导师，而不一定是得分高于其他导师 90% 的导师——但该奖项仍然为系里的导师提供了一个机会，使他们的简历和教学档案脱颖而出。

就其以数字形式分发、由多项选择题（加上一些简短回答）组成，且旨在作为期末总结性评估而言，ICaP SET 体现了

当前大学层面 SET 管理的流行趋势。在这项试点研究中，它被用作当前 SET 管理实践（通常所认为的）的代表。HET


与ICaP SET一样，HET也使用学生对问题的回答来产生一个分数，该分数旨在代表他们的教学能力。它有类似的题目数量（28道，而ICaP SET有34道）。然而，尽管这些表面上的相似之处存在，该工具的结构和内容与ICaP SET有很大的不同。

最显著的区别在于文本中项目的构建方式以及对这些项目的回答决定教师最终分数的方式。HET 中的项目不使用典型的李克特量表，而是提示学生用简单的“是/否”二元选择来回答一个问题。通过回答“是”和“否”来回答这些问题，学生回答者在一个分支的“树”状可能性地图中导航，其终点对应于一个 33 点序数标度上的点。

HET上的各项内容根据它们与教学结构中六个不同方面的相关性被分为六个套件。问题套件对应于量表分支路径上的方向节点，教师可以根据学生的回答向上或向下移动。如果学生对给定套件中的问题给予一定数量的“是”的回答（表明对教师教学的积极评价），教师就会向上移动。如果学生给予的“是”的回答不够，教师就会向下移动。因此，在学生回答完所有问题后，教师在可能性分支树上的“最终位置”对应于33点量表上的一个点。这种结构的可视化呈现见表1。

图1

HET 分支结构的图示



注释[AF32]: 表格和图形按顺序编号（即 1、2、3……）。它们通过二级标题（左对齐、粗体和标题大小写）以及简要描述表格或图形内容的斜体标题来识别。

注意: 此图中的每个节点对应于一系列 HET/ICALT 项目，而非单个项目。

高等教育评估（HET）中的问题源自国际比较分析

《学习与教学》（ICALT），一种用于衡量可观察教学行为的仪器

注释[AF33]: 表格和图表注释以斜体“注释”开头。适用于整个表格的一般注释应放在特定注释之前（用与图表或表格中特定位置相对应的上标小写字母表示）。表格注释是可选的。

欧盟内部国际教学研究的目的。ICALT的最新版本包含六个主题领域的32个项目，对应于六种广泛的教学技能。对于每个项目，学生以四点利克特量表对教师的陈述进行评分。在高等教育教学中使用ICALT项目的主要优势在于，它们在17年的开发过程中经过了多次独立测试，以验证其信度和效度（例如，参见Van de Grift，2007）。因此，它们的结果有助于教师之间的有意义的比较（同时也为管理人员提供了对教师建模教学结构本身的能力的合理水平的信心）。

高等教育评估测试（HET）中的六个“套件”问题，分别对应于国际教育技术协会（ICALT）的六个主题领域，在表 1 中呈现。

表1

HET 问题套件

套房	“物品数量；件数”	描述
安全的学习环境	4	老师是否能够 保持积极、非威胁性的 与学生的关系（以及） 培养这类关系 （在学生当中）
课堂管理	4	教师是否能够维持一个有序、可预测的环境。
清晰的说明	7	老师是否能够 解释课堂主题 显然，提供清晰的部分 关于作业的目标，并且 清晰地阐述之间的联系 这些作业和这节课 以有用的方式呈现主题。

注释[AF34]: 表格的排版方式与图形相似。它们以相同的方式编号和加标题，表格后的注释也以与图形后的注释相同的方式呈现。为表格和图形分别使用连续的序号。例如，尽管图形1在前，但此表格仍以表格1的形式呈现，而不是以表格2的形式呈现。

套房	“物品数量；件数”	描述	
激活教学方法	7	老师是否运用策略 这激励学生去思考 这堂课的主题。	
学习策略	6	教师是否采取明确的措施来教导学生如何学习 (而非仅仅为学生提供信息内容)。	
微分	4	教师能否成功 调整他们的行为以适应 个人多样化的学习需求 学生	

注意。项目编号源自原始的 ICALT 项目套件。

HET 上的项目仅在表述为二选一而非邀请对教师进行评价的情况下，才会对 ICALT 的项目进行修改。通常，这意味着在句子末尾加上“是否”这个词和一个问号。例如，ICALT 上的第二个安全学习环境项目表述为“教师保持轻松氛围”。在 HET 上，这个项目被重新表述为“教师是否保持轻松氛围？”更多示例项目见附录。

下面将讨论的是，项目套件的排序对教师的最终评分起着决定性的作用，因为分支量表对早期套件的分支比例影响更大。每个项目套件的“敏感度”（即在每个分支节点向上推进所需的积极响应数量）也是如此。这意味着地方利益相关者参与量表的开发非常重要。换句话说，这些利益相关者必须参与关于如何排序项目套件以及调整每个节点的敏感度的决策。下面将更详细地描述这一点。

一旦制定了量表，进行了评估，并获得了教师的最终评分，系统会提示学生评估者提供任何文字评论。[

AF35]: 当表格过长，跨越多页时，应在每页新页上重复列标题。大多数文字处理器都有自动实现这一功能。

评论[AF36]: 除了在正文中呈现图表外，您还可以在文档末尾的附录中呈现它们。您也可以使用附录来呈现在正文中会分散注意力或令人厌烦的材料。在这两种情况下，您都可以使用简单的正文内参考文献将读者引向附录。

一种新颖的教师评价模式

19

反馈他/她对课程体验的总结，无论是好是坏。类似于 ICaP SET 中的简短回复项目，此项目是可选的。简短回复项目如下：

对于这位老师，您会给出好的评价还是坏的评价？对于正在考虑选这门课的另一名学生，您又会怎么说？

最后四项是人口统计学问题。对于这些问题，学生需要表明他们的年级、他们对这门课程的预期成绩、他们的学校/学院（例如，文科学院、农业学院等），以及他们是作为选修课程还是作为学位要求来修这门课程。这些问题与 ICaP SET 的人口统计学项目相同。总之，HET 上的项目呈现如下：

- 分支二元问题（32 个不同的项目；六个分支）

这些问题为教师提供了数字评分。

- 简短响应提示（一项）
- 人口统计学问题（四项）

计分

该工具的主要数据来源于一个有 33 个点的分支序数标度上的终点。由于每个问题都以二元是/否选择的形式呈现（“是”表示老师更好），并且由于分支标度上的路径是根据老师在给定一组问题中是否收到所有“是”的回答来决定的，所以在前五组问题中可能会有 32 种可能的结果。例如，最糟糕的可能结果是连续五次“向下”分支，第二糟糕的可能结果是四次“向下”分支后跟一个“向上”分支，以此类推。第六组问题是一个决胜局：如果教师在这组问题中收到所有“是”的回答，就会额外获得一分。

通过在分支序列的早期将某些物品套件定位，HET 赋予了它们更大的权重。例如，第一套物品是最重要的：这里的“上升”会自动使教师在量表上高于 16 分，而“下降”则排除所有分数。

注释[AF37]：为简洁起见，原始论文接下来的几页内容已从这份样本文件中删减。

参考文献

- Ambady, N., & Rosenthal, R. (1993). Half a minute: Predicting teacher evaluations from thin slices of nonverbal behavior and physical attractiveness. *Journal of Personality and Social Psychology*, 64(3), 431–441. <http://dx.doi.org/10.1037/0022-3514.64.3.431>
- American Association of University Professors. (n.d.). Background facts on contingent faculty positions. <https://www.aaup.org/issues/contingency/background-facts>
- American Association of University Professors. (2018, October 11). Data snapshot: Contingent faculty in US higher ed. *AAUP Updates*. <https://www.aaup.org/news/data-snapshot-contingent-faculty-us-higher-ed#.Xfpdmy2ZNR4>
- Anderson, K., & Miller, E. D. (1997). Gender and student evaluations of teaching. *PS: Political Science and Politics*, 30(2), 216–219. <https://doi.org/10.2307/420499>
- Armstrong, J. S. (1998). Are student ratings of instruction useful? *American Psychologist*, 53(11), 1223–1224. <http://dx.doi.org/10.1037/0003-066X.53.11.1223>
- Attiyeh, R., & Lumsden, K. G. (1972). Some modern myths in teaching economics: The U.K. experience. *American Economic Review*, 62(1), 429–443. <https://www.jstor.org/stable/1821578>
- Bachen, C. M., McLoughlin, M. M., & Garcia, S. S. (1999). Assessing the role of gender in college students' evaluations of faculty. *Communication Education*, 48(3), 193–210. <http://doi.org/cqcgssr>
- Basow, S. A. (1995). Student evaluations of college professors: When gender matters. *Journal of Educational Psychology*, 87(4), 656–665. <http://dx.doi.org/10.1037/0022-0663.87.4.656>
- Becker, W. (2000). Teaching economics in the 21st century. *Journal of Economic Perspectives*, 14(1), 109–120. <http://dx.doi.org/10.1257/jep.14.1.109>
- Benton, S., & Young, S. (2018). Best practices in the evaluation of teaching. *Idea paper*, 69.

注释[AF38]: 参考文献列表应在新的一页上开始。“参考文献”（如果只有一个来源，则为“参考文献”）一词应以粗体并居中出现在页面顶部。参考文献条目应按字母顺序排列。文中引用的每一个来源都应有一个参考文献条目。

注释[AF39]: 有两个作者来源。

注释[AF40]: 所有引文条目都应双倍行距。在每个条目的第一行之后，接下来的每一行都应缩进半英寸（这被称为“悬挂缩进”）。

注释[AF41]: 具有组织作者来源。

[AF42] 评论道：请注意，如今在线学术出版物（如学术期刊）中的来源如果有数字对象标识符（DOI）或稳定的网址，则需要标注。

评论[AF43]: 缩短了数字对象标识符（DOI）。

- Berk, R. A. (2005). Survey of 12 strategies to measure teaching effectiveness. *International Journal of Teaching and Learning in Higher Education*, 17(1), 48–62.
- Bloom, B. S., Englehart, M. D., Furst, E. J., Hill, W. H., & Krathwohl, D. R. (1956). *Taxonomy of educational objectives: The classification of educational goals*. Addison-Wesley Longman Ltd.
- Brandenburg, D., Slinde, C., & Batista, J. (1977). Student ratings of instruction: Validity and normative interpretations. *Research in Higher Education*, 7(1), 67–78. <http://dx.doi.org/10.1007/BF00991945>
- Carrell, S., & West, J. (2010). Does professor quality matter? Evidence from random assignment of students to professors. *Journal of Political Economy*, 118(3), 409–432. <https://doi.org/10.1086/653808>
- Cashin, W. E. (1990). Students do rate different academic fields differently. In M. Theall, & J. L. Franklin (Eds.), *Student ratings of instruction: Issues for improving practice. New Directions for Teaching and Learning* (pp. 113–121).
- Centra, J., & Gaubatz, N. (2000). Is there gender bias in student evaluations of teaching? *The Journal of Higher Education*, 71(1), 17–33. <https://doi.org/10.1080/00221546.2000.11780814>
- Davis, B. G. (2009). *Tools for teaching* (2nd ed.). Jossey-Bass.
- Denton, D. (2013). Responding to edTPA: Transforming practice or applying shortcuts? *AILACTE Journal*, 10(1), 19–36.
- Dizney, H., & Brickell, J. (1984). Effects of administrative scheduling and directions upon student ratings of instruction. *Contemporary Educational Psychology*, 9(1), 1–7. [https://doi.org/10.1016/0361-476X\(84\)90001-8](https://doi.org/10.1016/0361-476X(84)90001-8)
- DuCette, J., & Kenney, J. (1982). Do grading standards affect student evaluations of teaching? Some new evidence on an old question. *Journal of Educational Psychology*, 74(3), 308–314. <https://doi.org/10.1037/0022-0663.74.3.308>

评论[AF44]: 纸质书。

评论[AF45]: 合集中的章节。

注释[AF46]: 印刷书籍的第二版。

注释[AF47]: 带有数字对象标识符 (DOI) 的学术文章不可用。

- Edwards, J. E., & Waters, L. K. (1984). Halo and leniency control in ratings as influenced by format, training, and rater characteristic differences. *Managerial Psychology*, 5(1), 1–16.
- Fink, L. D. (2013). The current status of faculty development internationally. *International Journal for the Scholarship of Teaching and Learning*, 7(2). <https://doi.org/10.20429/ijsofl.2013.070204>
- Fulcher, G. (2003). *Testing second language speaking*. Pearson Education.
- Fulcher, G., Davidson, F., & Kemp, J. (2011). Effective rating scale development for speaking tests: Performance decision trees. *Language Testing*, 28(1), 5–29. <https://doi.org/10.1177/0265532209359514>
- Gaff, J. G., & Simpson, R. D. (1994). Faculty development in the United States. *Innovative Higher Education*, 18(3), 167–76. <https://doi.org/10.1007/BF01191111>
- Hattie, J. (2008). *Visible learning: A synthesis of over 800 meta-analyses relating to achievement*. Routledge.
- Hoffman, R. A. (1983). Grade inflation and student evaluations of college courses. *Educational and Psychological Research*, 3(3), 51–160. <https://doi.org/10.1023/A:101557981>
- Howard, G., Conway, C., & Maxwell, S. (1985). Construct validity of measures of college teaching effectiveness. *Journal of Educational Psychology*, 77(2), 187–96. <http://dx.doi.org/10.1037/0022-0663.77.2.187>
- Kane, M. T. (2013) Validating interpretations and uses of test scores. *Journal of Educational Measurement*, 50(1), 1–73.
- Kelley, T. (1927) *Interpretation of educational measurements*. World Book Co.
- Knoch, U. (2007). Do empirically developed rating scales function differently to conventional rating scales for academic writing? *Spaan Fellow Working Papers in Second or Foreign Language Assessment*, 5, 1–36. English Language Institute, University of Michigan.
- Knoch, U. (2009). Diagnostic assessment of writing: A comparison of two rating scales. *Language Testing*, 26(2), 275–304.

[AF48] 评论道：为了简洁起见，原始论文接下来的几页内容已从这份样本文件中删减。

附录

为 HET 重新措辞的 ICALT 项目示例

套房	示例 ICALT 项目	荷兰语短语
安全的学习环境	老师倡导相互尊重。	老师提倡相互尊重吗？
课堂管理	这位老师有效地利用了学习时间。	老师能有效地利用学习时间吗？
清晰的说明	老师给学生反馈。	老师会给学生反馈吗？
激活教学方法	老师提供互动式教学和活动。	老师提供互动吗？ 指导和活动？
学习策略	老师提供互动 指导和活动	老师提供互动吗？ 指导和活动？
微分	教师根据学生之间的相关差异调整教学。	老师会适应吗？ 向相关人员下达指令 小学生之间的差异？

评论[AF49]: 附录在参考文献列表之后开始。“附录”一词应出现在页面顶部，加粗并居中。如果有多个附录，用大写字母标记它们（例如，附录A、附录B和附录C）。每个附录都应在新的一页上开始。

注释[AF50]: 正文段落也可出现在附录中。如果出现在附录中，段落应像正文段落一样正常缩进。

[AF51] 评论道: 如果附录中只包含单个表格或图形，就像这份一样，那么居中加粗的“附录”取代了通常伴随表格或图形的居中加粗的标签。

如果附录中**同时**包含文本、表格或图表，表格或图表应标注，且这些标注应包含附录的字母。例如，如果附录A包含两个表格和一个图表，它们应分别标注为“表A1”、“表A2”和“图A1”。附录B中的表格应标注为“表B1”。如果只有一个附录，则在表格/图表的标注中使用字母“A”：“表A1”、“表A2”等等。